Previsão de Resultados da Copa do Mundo de 2026 com Perceptron Multicamadas: Comparação com um Modelo Linear

Jefferson Santos Monteiro, Escola Politécnica, Universidade de São Paulo, São Paulo-SP, e-mail: jeffferson1227@usp.br.

***Resumo*— Este trabalho investiga a previsão de resultados (vitória da casa, empate ou vitória do visitante) das 104 partidas da Copa do Mundo de 2026 com um perceptron multicamadas em PyTorch, treinado com partidas internacionais de 2000 a 2026. As entradas são a diferença de rating Elo, o mando de campo, sua interação e a forma recente. Comparada a um baseline linear, a MLP obteve entropia cruzada semelhante (≈0,85 contra ≈0,84) e acurácia de 63,5%. Nenhum modelo prevê empates. Conclui-se que o Elo já embute grande parte da não-linearidade do problema.**

Palavras-Chave*— *Perceptron multicamadas, previsão esportiva, sistema Elo, calibração, Copa do Mundo.

***Abstract*— This work investigates the prediction of outcomes (home win, draw, or away win) of the 104 matches of the 2026 FIFA World Cup using a multilayer perceptron in PyTorch, trained on international matches from 2000 to 2026. Inputs are the Elo rating difference, home advantage, their interaction, and recent form. Compared with a linear baseline, the MLP achieved similar cross-entropy (≈0.85 versus ≈0.84) and 63.5% accuracy. Draws are never predicted. We conclude that the Elo rating already embeds much of the problem's nonlinearity.**

Keywords*— *Multilayer perceptron, sports prediction, Elo rating, calibration, World Cup.

I. Introdução

Prever o resultado de partidas de futebol é um problema de incerteza elevada: há poucos eventos por confronto, grande influência do acaso e um desfecho de três classes em que o empate é particularmente difícil de antecipar [1], [2]. Além de acertar a classe mais provável, interessa a qualidade das probabilidades estimadas, medida por entropia cruzada e calibração.

Este trabalho estima as probabilidades de vitória da casa, empate e vitória do visitante nas 104 partidas da Copa do Mundo de 2026, usando um perceptron multicamadas (MLP) em PyTorch, sem pré-treinamento. A principal variável de entrada deriva do sistema Elo [3], criado para ranquear jogadores de xadrez. Como controle experimental, a MLP é comparada a um baseline linear (regressão logística multinomial) com as mesmas entradas, perda e procedimento de treino, para testar, e não assumir, que a não-linearidade da rede agrega desempenho.

As contribuições são: (i) um protocolo de validação estritamente cronológico, com teste em um torneio real já concluído; (ii) a comparação controlada entre MLP e modelo linear; e (iii) a análise por classe, que evidencia a incapacidade dos modelos de prever empates.

II. Dados e Metodologia

A. **Base de dados e divisão.** Utilizou-se a base pública *International football results from 1872 to 2026* [4], com extensão comunitária que inclui as 104 partidas da Copa de 2026. O treino usa partidas de janeiro de 2000 até a véspera da Copa (25.354 jogos), e o teste, os 104 jogos do torneio. A divisão é cronológica, sem embaralhamento. Dentro do treino, os 10% finais, em ordem temporal, formam uma validação interna usada apenas para monitorar sobreajuste; o conjunto de teste não participa do treinamento.

B. **Sistema Elo.** O sistema Elo [3], criado para ranquear jogadores de xadrez, atribui a cada seleção um número, o rating, que resume sua força relativa: quanto maior, mais forte. Nas equações abaixo, R_A é o rating da seleção A e R_B o da seleção B imediatamente antes da partida; todas as seleções começam em 1500. A pontuação esperada de A contra B é:

$$E_A = \frac{1}{1+10^{(R_B-R_A)/400}} \quad (1)$$

e depende apenas da diferença entre os ratings: com ratings iguais, E_A = 0,5; com 400 pontos de vantagem, E_A ≈ 0,91. Após cada partida, o rating é atualizado pela diferença entre o resultado real e o esperado:

$$R_A \leftarrow R_A + K(S_A - E_A) \quad (2)$$

em que S_A vale 1 (vitória), 0,5 (empate) ou 0 (derrota) e K = 20 limita o tamanho do ajuste. Assim, vencer um favorito rende mais pontos que vencer um azarão. O rating de B é atualizado de forma simétrica, de modo que o total de pontos se conserva. Por exemplo, com R_A = 1600 e R_B = 1500, tem-se E_A ≈ 0,64; se A vencer, passa a ≈1607,2 (e B a ≈1492,8); se empata, A cai para ≈1597,2; se perde, para

≈1587,2. O rating é calculado sequencialmente do primeiro jogo da base (1872) até o último disponível, sem reinicialização em 2000: o corte de 2000 define apenas quais partidas compõem o treino. Esta versão do Elo usa K constante, sem termo de mando de campo e sem margem de gols.

C. **Variáveis de entrada.** São quatro: (i) *elo_diff*, diferença de Elo entre mandante e visitante; (ii) *home_flag*, igual a 1 se a partida não ocorre em campo neutro e 0 caso contrário; (iii) *elo_home_interaction*, produto de *elo_diff* e *home_flag*, que captura a variação do efeito do mando com a diferença de força; e (iv) *form_diff*, diferença de pontos (3 por vitória, 1 por empate, 0 por derrota) nos últimos 10 jogos de cada seleção. As entradas são padronizadas com a média e o desvio do treino.

D. **Prevenção de vazamento.** Cada atributo é calculado antes de o resultado da própria partida atualizar o Elo e a forma. Assim, o vetor de entrada de um jogo depende somente de partidas anteriores, inclusive dentro da Copa, em que os ratings continuam evoluindo jogo a jogo.

III. Modelos

A. **MLP.** A rede possui uma camada oculta de 16 neurônios com ReLU e dropout de 0,2 [8], seguida de camada de saída com 3 neurônios e softmax (131 parâmetros treináveis). A camada oculta usa inicialização de He [6], projetada para ReLU, e a de saída, inicialização de Xavier [7].

B. **Justificativa das escolhas.** Com quatro entradas e cerca de 23 mil exemplos de treino (90% dos 25.354 jogos), uma camada oculta de 16 neurônios (131 parâmetros) dá folga de aproximadamente 170 exemplos por parâmetro e capacidade suficiente para testar se há não-linearidade além do Elo, sem favorecer sobreajuste. Usou-se ReLU na camada oculta, com inicialização de He, que preserva a variância das ativações; a saída é softmax de três classes. A função custo é a entropia cruzada, que é a log-verossimilhança negativa de um modelo categórico e uma regra de pontuação própria: seu mínimo ocorre nas probabilidades verdadeiras, o que alinha o treino ao objetivo de estimar probabilidades calibradas (a acurácia ignora a confiança e não é diferenciável). O otimizador é o Adam (taxas adaptativas por parâmetro, pouca sensibilidade à escala dos gradientes), com taxa 10^{-3}, minibatch de 64 e 100 épocas, valores cuja robustez foi verificada na Tabela II e que a curva de aprendizado (Fig. 1) corrobora, pois estabiliza em ~20 épocas. Weight decay de 10^{-4} e dropout de 0,2 atuam como regularização leve. As entradas são padronizadas com média e desvio do treino, pois *elo_diff* (centenas) e *form_diff* (dezenas) têm escalas distintas. A métrica principal é a entropia cruzada, pelo mesmo motivo; a acurácia é secundária, e AUC por classe, matriz de confusão e calibração diagnosticam onde o modelo falha.

C. **Baseline linear.** Uma única transformação linear das quatro entradas para três saídas, seguida de softmax (15 parâmetros), isto é, regressão logística multinomial. É a MLP sem camada oculta. Usa a inicialização padrão do PyTorch [9].

D. **Treinamento.** Ambos os modelos usam a entropia cruzada,

$$L = -\frac{1}{N}\sum_{i=1}^{N} log(p_{i,yi}) \qquad (3)$$

otimizada com Adam [5], taxa de aprendizado 10^{-3}, *weight decay* 10^{-4}, minibatch de 64 e 100 épocas. Esses valores seguem práticas usuais da literatura e não foram obtidos por busca contra o conjunto de teste.

IV. Resultados

Os resultados no conjunto de teste estão na Tabela I. Para interpretar a Tabela I, é preciso uma referência. O modelo sem informação ignora as entradas e atribui a todo jogo as frequências de classe do treino (≈48% casa, ≈23% empate, ≈29% visitante); sua entropia cruzada é 1,0541 (probabilidades uniformes, $\frac{1}{3}$ para cada classe, dariam $ln\,(3) \approx 1,10$) e sua acurácia, 47,12%, equivale a sempre prever vitória da casa. Os modelos treinados reduzem a entropia cruzada para ≈0,84-0,85 e elevam a acurácia a 63,5%, o que mostra que as entradas, em especial o Elo, carregam informação genuína sobre o resultado. Ao mesmo tempo, como linear e MLP chegam ao mesmo patamar, a camada oculta não extrai informação adicional mensurável.

Tabela I: Desempenho nos 104 jogos da Copa de 2026.

Métrica	Linear	MLP
Entropia cruzada	0,8391	0,8484
Acurácia	63,5%	63,5%
AUC home_win	0,781	0,781
AUC draw	0,554	0,562
AUC away_win	0,887	0,885

O modelo linear apresenta entropia cruzada ligeiramente menor que a MLP (≈0,84 contra ≈0,85). A diferença, entre 0,007 e 0,009, é consistente entre sementes nas variações de épocas e minibatch (Tabela II), mas é pequena e, com apenas 104 jogos de teste, não permite afirmar superioridade de um dos modelos. A Tabela I refere-se aos modelos finais (semente

42), enquanto a linha base da Tabela II é a média de cinco sementes, o que explica a pequena diferença numérica.

Tabela II: Entropia cruzada no teste (média ± desvio, 5 sementes). Variação de um fator por vez.

Configuração	Linear	MLP
Base (100 épocas, minibatch 64, lr 10^{-3})	0,8415 ± 0,0010	0,8487 ± 0,0021
50 épocas	0,8406 ± 0,0011	0,8487 ± 0,0018
200 épocas	0,8408 ± 0,0005	0,8486 ± 0,0011
400 épocas	0,8415 ± 0,0006	0,8491 ± 0,0015
Minibatch 32	0,8419 ± 0,0016	0,8499 ± 0,0031
Minibatch 128	0,8412 ± 0,0006	0,8486 ± 0,0013
Minibatch 256	0,8412 ± 0,0004	0,8491 ± 0,0022
lr 10^{-2}	0,8493 ± 0,0046	0,8556 ± 0,0087
lr 10^{-4}	0,8523 ± 0,0040	0,8528 ± 0,0058
lr 10^{-5}	0,9531 ± 0,0661	0,8860 ± 0,0263
Inicialização padrão do PyTorch	—	0,8516 ± 0,0031

Para avaliar a robustez, variou-se um fator por vez (épocas, minibatch, taxa de aprendizado e, na MLP, a inicialização), com cinco sementes por configuração (Tabela II). Épocas entre 50 e 400 e minibatch entre 32 e 256 não alteraram a entropia cruzada além do desvio entre sementes (≈0,001–0,003). Taxas de aprendizado maiores (10^{-2}) ou menores (10^{-4} e 10^{-5}) pioraram o resultado; com 10^{-5}, o treino de 100 épocas é insuficiente (subajuste). A inicialização padrão do PyTorch produziu entropia cruzada ligeiramente maior que a de He/Xavier (0,8516 contra 0,8487). Como essas variações foram avaliadas no conjunto de teste, têm caráter exploratório e não foram usadas para escolher hiperparâmetros; os valores originais foram mantidos.

A curva de aprendizado (Fig. 1) mostra convergência estável e sem sobreajuste evidente.

A curva de calibração (Fig. 2) compara, por faixa de probabilidade prevista, a frequência observada de cada classe com a diagonal ideal: as probabilidades de vitória ficam relativamente próximas da diagonal em faixas intermediárias, enquanto o empate apresenta desvios mais acentuados, sobretudo perto de 0,3. Como há poucos jogos por faixa de probabilidade, as curvas são ruidosas, sobretudo nas faixas extremas.

A matriz de confusão (Fig. 3) mostra que a MLP acerta 42 das 49 vitórias da casa e 24 das 31 vitórias do visitante, mas nunca prediz empate: dos 24 empates reais, 18 foram classificados como vitória da casa e 6 como vitória do visitante. A curva ROC (Fig. 4) confirma esse padrão, com AUC de 0,78 e 0,89 para vitória da casa e do visitante e apenas 0,56 para empate, próximo do acaso. Um exemplo é Brasil × Marrocos, previsto como vitória do Brasil e encerrado em empate. A matriz de confusão do modelo linear é idêntica à da MLP, e os valores de AUC diferem em menos de 0,01 (Tabela I), o que reforça que os dois modelos extraem a mesma informação das quatro entradas.

O viés é sistemático: os empates reais são deslocados para a vitória da casa e não distribuídos ao acaso. O padrão se mantém em campo neutro (*home_flag* = 0), em que o rótulo "casa" é apenas nominal: dos 23 empates disputados em campo neutro, 17 foram classificados como vitória da casa. Isso é consistente com a distribuição das classes, pois no treino a vitória da casa responde por ≈48% das partidas, a do visitante por ≈29% e o empate por ≈23%. Como a classe com maior probabilidade é a escolhida, o empate só seria previsto se fosse a maior das três probabilidades (o que exige, no mínimo, superar $\frac{1}{3}$), e as probabilidades previstas para essa classe permanecem em torno de 0,3 ou menos (Fig. 2).

Figura 1: Curva de aprendizado da MLP.

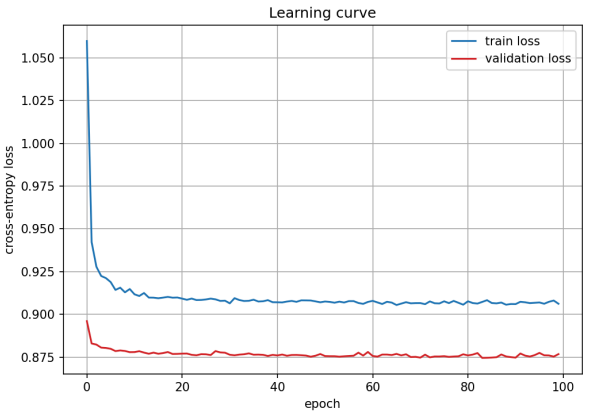


Figura 2: Curva de calibração no conjunto de teste.

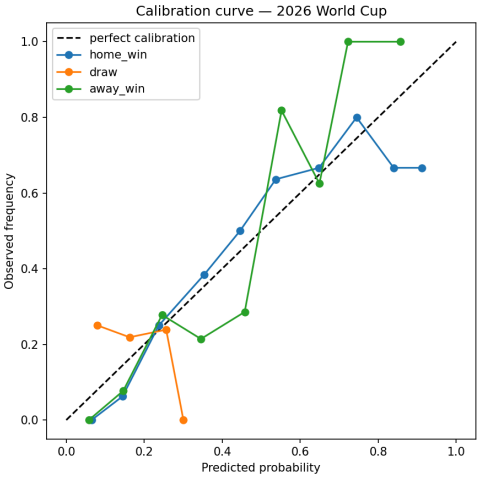


Figura 3: Matriz de confusão da MLP na Copa de 2026.

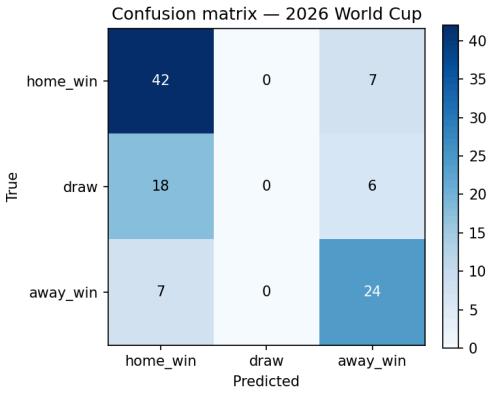
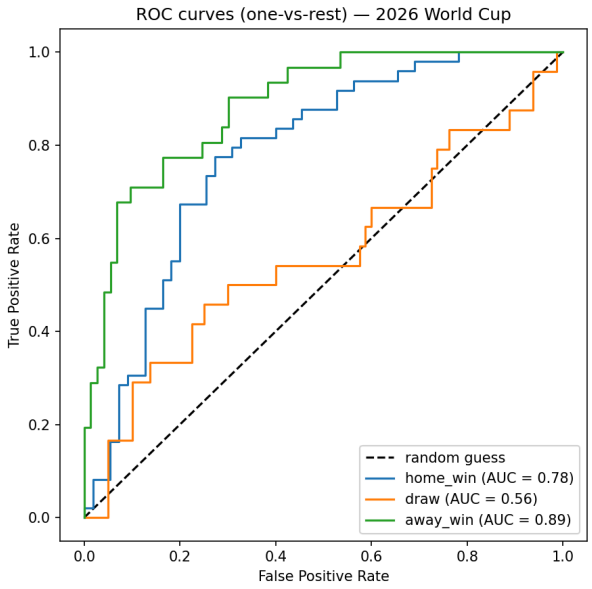


Figura 4: Curvas ROC por classe.



V. Discussão e Limitações

Hipótese e achado. O plano de trabalho propunha treinar uma MLP com atributos derivados do Elo e verificar se suas probabilidades eram bem calibradas em um torneio real. O baseline linear não fazia parte do plano: foi acrescentado durante o desenvolvimento como controle experimental, para testar se a não-linearidade da rede se justificava, como a disciplina exige. O resultado foi que o modelo linear igualou a MLP, com leve vantagem em entropia cruzada. Isso não invalida o uso da MLP, que é o modelo central do trabalho; ao contrário, foi a comparação controlada com o baseline que permitiu descobrir que a não-linearidade não era necessária. Em teoria, prever resultados de futebol parece exigir um modelo não linear; na prática, com estes atributos, essa estrutura já estava embutida no Elo, cuja pontuação esperada é uma função logística que o softmax de uma combinação linear aproxima. A camada oculta, portanto, não extraiu informação adicional mensurável. O achado vale para este conjunto de quatro atributos e uma rede rasa; atributos mais ricos (como gols esperados e composição das equipes) poderiam voltar a justificar a não-linearidade.

Linear versus MLP. À primeira vista, o resultado pode parecer trivial: com apenas quatro entradas, seria de esperar que um modelo linear bastasse. Entretanto, o número de entradas não determina a linearidade do problema. O caso clássico é a porta XOR, com apenas duas entradas, cujas classes não podem ser separadas por nenhuma fronteira linear e que exige uma camada oculta. Aqui, a situação é a oposta, por causa da forma da Eq. (1). Como

$$\frac{1}{1+10^{-d/400}} = \frac{1}{1+e^{-0{,}00576 \cdot d}}$$

com:

$$d = R_A - R_B$$

A pontuação esperada do Elo é uma função logística da diferença de rating, isto é, a mesma forma funcional que a regressão logística (e, com três classes, a regressão logística multinomial) já representa ao aplicar softmax a uma combinação linear das entradas. O baseline linear, portanto, reproduz essa relação sem camada oculta. A única interação com justificativa de domínio, *elo_home_interaction*, foi construída manualmente na engenharia de atributos e é fornecida a ambos os modelos como mais uma entrada. Resta pouca estrutura não-linear residual para a camada oculta aprender, o que explica o desempenho semelhante. Esse resultado é tratado como achado, não como falha: a não-linearidade relevante foi capturada nos atributos, não na arquitetura. Ressalte-se que isso só pôde ser afirmado porque o baseline foi treinado e comparado, e não assumido.

Empates. A dificuldade de prever empates é documentada na literatura [1], [2], e a quase ausência de empates entre as previsões de modelos baseados em rating é relatada em [1]. No presente caso, o desvio dos empates para a vitória da casa decorre do critério de decisão (classe de maior probabilidade) combinado ao prior das classes.

Limitações.

- O teste tem 104 jogos, e diferenças pequenas, como a de entropia cruzada entre os modelos, podem refletir apenas a variação amostral. Além disso, a grande maioria das partidas da Copa tem *home_flag* = 0, restando apenas os jogos das seleções-sede (Estados Unidos, México e Canadá) para exercitar o mando de campo.
- Os hiperparâmetros seguem valores usuais da literatura e não foram otimizados por busca sistemática. A análise de sensibilidade da Seção IV (épocas, minibatch, taxa de aprendizado e inicialização) não identificou configuração que

melhorasse a entropia cruzada além do desvio entre sementes. O dropout não foi variado, e a estrutura da camada oculta só foi alterada na rede mais profunda descrita a seguir.

- Uma rede mais profunda (quatro camadas ocultas, com 32 neurônios na primeira e metade dos neurônios a cada camada seguinte) e a ponderação de classes foram avaliadas e descartadas por piorarem o resultado. Como essas variações foram observadas no conjunto de teste, e não em uma validação separada, os resultados dessa análise têm caráter exploratório. O ideal seria uma segunda validação cronológica, mantendo a Copa intocada até a avaliação final.

VI. Conclusões

Este trabalho comparou uma MLP e um modelo linear na previsão das partidas da Copa de 2026, com divisão cronológica e prevenção explícita de vazamento. Os modelos tiveram entropia cruzada semelhante, com leve vantagem do linear (entropia cruzada ≈0,85 para a MLP e ≈0,84 para o modelo linear; acurácia de 63,5% em ambos), indicando que, com atributos derivados do Elo, o problema é aproximadamente linear. O baseline linear, acrescentado como controle, mostrou que a não-linearidade da rede não era necessária, o que constitui um achado científico, e não uma falha do modelo. Ambos preveem bem vitórias, mas não empates, padrão consistente com a literatura. Como trabalhos futuros, propõem-se atributos mais ricos (por exemplo, composição das equipes e gols esperados), otimização sistemática de hiperparâmetros e análise de interpretabilidade.

Referências

[1] Y. Ren e T. Susnjak, "Predicting football match outcomes with eXplainable machine learning and the Kelly index", arXiv:2211.15734, 2022.

[2] B. S. Choi, L. K. Foo e S.-L. Chua, "Predicting football match outcomes with machine learning approaches", *MENDEL*, v. 29, n. 2, pp. 229–236, 2023.

[3] A. E. Elo, *The Rating of Chess Players, Past and Present*. Arco Publishing, 1978.

[4] M. Jürisoo, "International football results from 1872 to 2026", *Kaggle*, 2026. Disponível em: https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017. Acesso em: 12 set. 2026.

[5] D. P. Kingma e J. Ba, "Adam: a method for stochastic optimization", arXiv:1412.6980, 2014.

[6] K. He, X. Zhang, S. Ren e J. Sun, "Delving deep into rectifiers: surpassing human-level performance on ImageNet classification", *Proc. IEEE ICCV*, 2015.

[7] X. Glorot e Y. Bengio, "Understanding the difficulty of training deep feedforward neural networks", *Proc. AISTATS*, 2010.

[8] N. Srivastava *et al.*, "Dropout: a simple way to prevent neural networks from overfitting", *J. Mach. Learn. Res.*, v. 15, pp. 1929–1958, 2014.

[9] A. Paszke *et al.*, "PyTorch: an imperative style, high-performance deep learning library", *Advances in Neural Information Processing Systems*, v. 32, 2019.

Apêndice

APÊNDICE A – Memorial Completo de Código-Fonte

Este apêndice compreende o memorial completo do código-fonte desenvolvido no projeto, incluindo a implementação da rede neural, o modelo linear e o notebook python respectivo.

Considerando a complexidade e o volume do código, o material foi disponibilizado em repositório público de versionamento, conforme link a seguir:

Disponível em:
https://github.com/Jeff-Santz/tf-psi0325-cup2026